XXI Jornada Científica
Faculdades Integradas de Bauru - FIB
ISSN 2358-6044
2026

PREVISÃO DE RESULTADOS DO BRASILEIRÃO COM GRADIENT BOOSTING E RATING ELO

Rafaela Oliveira Viol[1]; Felipe Yuji Sato Silva[2]; Luis Henrique Balduino Neto Comini[3]; Henrique Meneses Catanho da Silva [4]; Ronaldo Cesar Dametto [5]
[1]Aluna do curso de Ciência da Computação – Faculdades Integradas de Bauru – FIB - rafaelaoliveiraviol@gmail.com
[2]Aluno do curso de Ciência da Computação – Faculdades Integradas de Bauru – FIB – fsato195@gmail.com
[3]Aluno do curso de Ciência da Computação – Faculdades Integradas de Bauru – FIB – luishcomini123@gmail.com
[4]Aluno do curso de Ciência da Computação – Faculdades Integradas de Bauru – FIB – henriquecatanho01@gmail.com
[5] Professor do curso de Ciência da Computação – Faculdades Integradas de Bauru – FIB – ronaldo.dametto@fibbauru.br.

Grupo de trabalho: Ciência da Computação

Palavras-chave: gradient boosting; XGBoost; rating Elo; previsão de resultados; futebol

Introdução: Prever o resultado de uma partida de futebol é difícil, pois há poucos gols e grande componente de acaso. Ainda assim, analistas e jornalistas esportivos precisam estimar o desempenho das equipes com base em dados. O Gradient Boosting constrói árvores de decisão em sequência, cada uma corrigindo os erros da anterior (FRIEDMAN, 2001), e o XGBoost é uma implementação eficiente dessa ideia, com regularização e tratamento de valores ausentes (CHEN; GUESTRIN, 2016). Na literatura, árvores de gradient boosting foram a abordagem vencedora do Soccer Prediction Challenge 2017 (HUBÁČEK; ŠOUREK; ŽELEZNÝ, 2019), e comparações entre XGBoost, LightGBM e CatBoost reportam acurácias em torno de 55% para três classes (RAZALI et al., 2022). Esses estudos destacam que a qualidade das variáveis de entrada pesa tanto quanto a escolha do algoritmo, em especial os ratings de força das equipes.

Objetivos: Desenvolver e avaliar um modelo XGBoost que estime a probabilidade de vitória, empate ou derrota do mandante no Campeonato Brasileiro; verificar se o rating Elo melhora a previsão em relação a médias simples de desempenho; comparar o modelo a uma Regressão Logística; analisar seus erros; e disponibilizar uma demonstração web interativa.

Relevância do Estudo: Há menos trabalhos sobre o Brasileirão com estatísticas de jogo do que sobre ligas europeias. O estudo documenta o que funciona e o que não funciona nesse contexto, inclusive resultados negativos, e transforma o modelo em uma ferramenta compreensível por público não especialista.

Material e métodos: Foram utilizadas partidas do Campeonato Brasileiro de 2015 a 2023 (3.154 jogos após o tratamento), com estatísticas por time e partida (gols, chutes, chutes no alvo, posse de bola e escanteios) do repositório público Brasileirao_Dataset (DUQUE, [s.d.]). Para cada jogo, calcularam-se médias dos últimos cinco jogos de cada equipe usando apenas partidas anteriores, para evitar vazamento de dados. Rating é uma nota numérica de força do time, atualizada após cada partida; o Elo é um sistema de rating em que o ganho de pontos é maior quando o resultado é inesperado. A média dos últimos jogos não distingue contra quais adversários o time jogou, e o rating incorpora essa informação. Por isso, motivados por Razali et al. (2022) e Hubáček, Šourek e Železný (2019), que usaram ratings como variáveis de modelos de boosting, e por Constantinou e Fenton (2013), que mostram que ratings dinâmicos superam o Elo clássico, adotou-se o Elo, versão mais simples e calculada só com placares, o que também atende à recomendação de incorporar conhecimento do domínio (BERRAR; LOPES; DUBITZKY, 2019). O Elo entra como variável do XGBoost, que segue sendo o algoritmo estudado, e é calculado antes de cada jogo. A divisão foi temporal: treino de 2015 a 2020, validação em 2021 e teste em 2022 e 2023. O XGBoost foi comparado a uma Regressão Logística com scikit-learn (PEDREGOSA et al., 2011) com e sem o Elo. Avaliaram-se acurácia, log-loss, F1 macro e desempenho por classe.

Resultados e discussões: A inclusão do Elo permitiu incorporar a força relativa das equipes ao modelo, e a diferença entre os ratings apresentou importância de 0,1476. O XGBoost ajustado alcançou 52,11% de acurácia e F1-macro de 0,3894. Apesar do resultado, a identificação de empates permaneceu como uma limitação, evidenciando a necessidade de aprimorar a classificação das diferentes classes. Sem o Elo, nos jogos de teste, a Regressão Logística obteve acurácia de 0,483, log-loss de 1,046 e F1 macro de 0,327; o XGBoost obteve 0,448, 1,058 e 0,260. A hipótese de que o XGBoost superaria o modelo linear não foi confirmada nessa configuração. A principal dificuldade foi a classe Empate, com revocação de 1% no XGBoost, pois o modelo tende a prever a classe mais frequente (vitória do mandante, cerca de 45% dos jogos de teste). Os valores ficam abaixo dos reportados na literatura para configurações com ratings (RAZALI et al., 2022), o que sustenta o teste do Elo.

Conclusão: Sem ratings, o gradient boosting não superou um modelo linear com poucos dados e poucas variáveis, e os empates seguem como o principal limite. A diferença entre os ratings Elo mostrou-se relevante para as previsões do modelo. Como continuidade, propõe-se comparar experimentalmente as versões com e sem Elo, além de investigar outros sistemas de rating, ajustar os hiperparâmetros e adotar estratégias para melhorar a identificação de empates.

Referências

BERRAR, D.; LOPES, P.; DUBITZKY, W. Incorporating domain knowledge in machine learning for soccer outcome prediction. **Machine Learning**, v. 108, p. 97–126, 2019.

CHEN, T.; GUESTRIN, C. XGBoost: a scalable tree boosting system. In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 22., 2016. **Proceedings** [...]. New York: ACM, 2016. p. 785–794.

CONSTANTINOU, A. C.; FENTON, N. E. Determining the level of ability of football teams by dynamic ratings based on the relative discrepancies in scores between adversaries. **Journal of Quantitative Analysis in Sports**, v. 9, n. 1, p. 37–50, 2013.

DUQUE, A. L. **Brasileirao_Dataset**. [S. l.]: GitHub, [s.d.]. Disponível em: https://github.com/adaoduque/Brasileirao_Dataset. Acesso em: out. 2026.

FRIEDMAN, J. H. Greedy function approximation: a gradient boosting machine. **Annals of Statistics**, v. 29, n. 5, p. 1189–1232, 2001.

HUBÁČEK, O.; ŠOUREK, G.; ŽELEZNÝ, F. Learning to predict soccer results from relational data with gradient boosted trees. **Machine Learning**, v. 108, p. 29–47, 2019.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.

RAZALI, M. N. et al. Football matches outcomes prediction based on gradient boosting algorithms and football rating system. In: AHFE INTERNATIONAL CONFERENCE, 2022. **Human Factors in Software and Systems Engineering**, v. 61, p. 57–66, 2022.